

AutoResearch

证据约束的科研闭环基础设施

基于 Qwen、科研状态契约与三层门禁的
Science 125 问 AI Scientist 技术方案

一句话价值主张

把大模型的科研推理转化为可追溯、可复核、可阻断、可迭代的科研状态流，使“生成建议”升级为“依据真实证据推进下一步研究”。

项目编号	XH-202619					
参赛方向	赛道一：科学问题 · 方向 1A 科学假设生成与研究计划设计					
项目团队	AutoResearch 项目组					
版本日期	2026 年 8 月					

目录

评委阅读路径

目录

项目总览	3
1 赛题挑战与现有方案缺口	4
2 核心设计目标	4
3 核心创新总览	4
4 系统总体架构	5
4.1 五层架构与三类流	5
5 证据图谱与科研状态契约	6
5.1 对象关系：让每个结论有来源、状态和版本	6
6 临时智能体与可审计 Skills	7
6.1 按任务创建、按角色授权、完成后销毁	7
7 十二阶段科研闭环与状态机	8
7.1 科研状态机：只有证据满足条件，状态才能跃迁	8
7.2 状态跃迁的最小判据	8
7.3 十二阶段不可变 checkpoint	9
8 真实执行、数值守卫与三层门禁	10
8.1 从计划中的变量到可复核观测	10
8.2 三层门禁的职责边界	10
9 Science 125 问成果总览	11
9.1 规模化交付的真实状态，而非“125 次实验”	11
10 q001 真实 pilot：可信闭环压力测试	12
10.1 从开放问题到“应当收缩结论”的真实反馈	12
11 系统评估、消融与竞品对比	13
11.1 把“已有实测”与“计划评估”分开	13
11.2 待补实验矩阵	13
11.3 基于论文与官方仓库的克制对照	14
12 工程实现、部署与复现	14
12.1 最小复现顺序	14
13 安全边界、应用价值与下一阶段计划	15
13.1 安全不是附加声明，而是状态跃迁条件	15
13.2 应用价值	15
13.3 下一阶段路线图	15
结论	15
附录：证据索引、复核路径与参考文献	16

建议阅读路径

20 秒 P3

定位、成果、边界

1 分钟 P4

六项核心创新

5 分钟 P5–P10

架构、状态、闭环、门禁

10 分钟 P11–P16

125 问、q001、评估与证据索引

证据状态图例

运行证据：已有运行产物

代码契约：实现已核验，效果未必实测

【待补实验】：尚无可报告结果

阻断：门禁拒绝继续流转

文档导航说明：目录条目、章节标题和参考文献均建立 PDF 超链接与书签。主文保留评委作出判断所需的机制和证据；完整代码路径、运行目录、指标与补证协议集中于附录。

项目总览

一图读懂

项目定位

AutoResearch 不是“自动写论文”的聊天机器人，而是一套证据优先的 AI Scientist 科研状态机：以 Qwen 承担规模化推理，以临时智能体与 Skills 执行方法，以证据哈希、checkpoint、数值/引用守卫和三层门禁约束每一次状态跃迁。

- 问题 1 | 证据漂移

文献事实、模型推断与实验观测容易混写。
- 问题 2 | 过程不可复核

多轮生成覆盖中间状态与失败原因。
- 问题 3 | 自动化无边界

结构合规、科学合理与责任授权被混为一谈。



- 01 科研状态契约

稳定 ID + 内容哈希绑定证据、计划、观测与决策。
- 02 临时智能体 + Skills

按任务创建、最小授权、结构回执、执行后清理。
- 03 原始证据/派生记忆分离

摘要只导航，不能升级为科学证据。
- 04 不可变科研闭环

十二阶段 checkpoint，失败另存 artifact。
- 05 数值/引用 + 三层门禁

无法溯源即拒绝；结构、科学、责任分层判定。
- 06 规模化任务编译

125 问转为带数据、基线、指标和终止条件的计划。

125/125	125	125	1	4	major	已阻断
结构化研究计划	Markdown	PDF	q001 真实 pilot	零模型	revision	自动交付

当前能力边界

125 份是研究计划，不是 125 项已执行实验；q050、q091、q119 为领域定制计划态样例。q001 是探索性计算，没有证明任何素数猜想。Qwen 是当前核心，端点与供应商由配置替换。

- 当前状态快照 | 已经发生

- 125 题均形成结构化计划与双格式交付；
 - q001 完成真实探索性计算并锁定原始产物；
 - 独立评审发现 2 项 major、2 项 minor 问题；
 - 阻断回执被保存，自动交付未发生。
- 下一步验证 | 尚未发生

- 其余 124 题需按数据与适配器条件逐题执行；
 - 125 题内部 JSON Schema 批量复核待完成；
 - 数字/引用对抗、恢复、成本与消融均待实验；
 - Skill 影子评估已有契约，真实晋级链待补。

20 秒判断句

输入不是一段提示词，输出也不只是一篇文本：输入被编译为科研对象，输出携带证据绑定、状态、版本与门禁结论；系统既能推进，也能在证据不足时留下可解释的停止点。

1 赛题挑战与现有方案缺口

挑战	常见失效方式	AutoResearch 的控制点
从开放问题到可证伪任务	输出泛化建议，缺变量、对照、判据和停止条件	任务编译 Schema 固化科学目标、竞争解释、数据、基线、指标与资源
证据进入推理链	检索内容、模型记忆和真实观测混写	锁定引用目录；原始证据不可覆盖；派生记忆显式标记为非证据
反馈真正改变状态	评审只是文末意见，下一轮生成可绕过失败	checkpoint + 阻断回执；评审结论决定可交付、修订或停止

2 核心设计目标

G1 可检查 每个结论可定位到对象、文件与哈希。	G2 可验证 假设附带对照、指标和反证条件。	G3 可迭代 评审与观测形成下一轮显式输入。	G4 可负责 高风险执行和交付必须经过责任门禁。
------------------------------------	----------------------------------	----------------------------------	------------------------------------

3 核心创新总览

一级创新	解决的问题	核心机制与差异	当前证据
证据绑定的科研状态契约	对话与摘要不可稳定复核	状态对象 + 稳定 ID + 哈希；计划/观测、原始/派生分别建模	运行证据 + 代码契约
临时智能体与可审计 Skills	常驻 Agent 权限与上下文污染	按任务装配权限、证据、Skill、Schema 和预算；保留路由理由与哈希	运行证据 + 代码契约
受控 Skill 进化	错误经验直接写回系统	开发/隐藏证据分区、影子评估、晋级与回滚；安全规则不可自改	代码契约；【待补实验】
十二阶段不可变闭环	失败被重生成覆盖	阶段 checkpoint、上游哈希引用、failure artifact 与反馈回灌	运行证据 + 代码契约
数值/引用守卫与三层门禁	编造数字、假引用、责任不清	数值占位绑定、引用精确投影；机器/科学/人类分层判定	前两层有运行证据
确定性交付与任务编译	文本难执行、多格式漂移	同源渲染 MD/TeX/PDF/manifest；125 问编译为研究协议	运行证据 + 代码契约

为什么这不是普通 RAG 或多智能体编排

RAG 决定“取回什么”，多智能体框架决定“谁与谁通信”；AutoResearch 进一步决定什么可被认定为证据、当前处于何种科研状态、能否跃迁、失败如何保留、谁对执行和交付负责。差异化来自状态与门禁契约，而非 Agent 数量或提示词长度。

创新证据状态：不把设计愿景写成运行结论

运行级 q001 证据状态、checkpoint、临时交互、真实 pilot、独立评审与阻断；125 题双格式交付。	代码级 状态 Schema、原始/派生分离、最小权限、数值/引用守卫、确定性渲染与 Skill 影子晋级契约。	待验证级 受控 Skill 晋级效果、批量守卫性能、checkpoint 恢复、跨模型消融、成本与人工修改量。
--	---	---

一级创新的判定规则

本方案只把有代码或运行对象的机制列为核心创新；运行效果尚未测量时，明确保留【待补实验】，不以架构图替代证据。

4 系统总体架构

4.1 五层架构与三类流



图 1: AutoResearch 总体分层架构。数据、权限和反馈采用统一线型；红色节点是可真实失败的控制点。

Qwen 的位置	可替换边界	未宣称内容
当前推理核心，承担问题收窄、假设生成、计划修订等认知任务；模型回执记录 provider 与 model。	代码从配置读取 <code>base_url</code> 、 <code>api_key</code> 、 <code>model_name</code> ；密钥不进入产物与版本库。	尚无跨供应商问题质量、时延与成本对照；“可替换”是接口能力，不是性能等价结论。

跨层约束与可检查输出

约束面	在哪一层实施	评委可检查的输出
数据边界	证据层锁定文件、引用与哈希；编排层验证绑定	manifest、verified files、引用目录状态、输入/产物哈希
权限边界	编排层下发角色策略；Agent/Skill 层只获得必要工具	任务 Schema、Skill manifest、允许的证据子集、清理/紧急回执
状态边界	编排层状态机区分计划、执行、观测、评审与交付	checkpoint、parent hash、状态字段、failure/block receipt
责任边界	机器、科学与人类门禁各自独立作出判定	字段级拒绝、独立 recommendation、授权/保持/拒绝记录

架构判定原则
任何智能体都不能仅凭自然语言“宣布成功”改变科研状态；状态提升必须由编排层读取结构化回执和已验证证据，并满足相应门禁条件。

5 证据图谱与科研状态契约

5.1 对象关系：让每个结论有来源、状态和版本




图 2: 证据对象关系。实线表示数据/产物绑定，虚线表示受限使用，点线表示反馈生成新版本。

科研状态契约		
一个可信状态可抽象为 $S_t = \langle id, type, payload, evidence_bindings, parent_hash, artifact_hash, status \rangle$ 。下游只能引用已验证的 S_t ；任何字段变化都会产生新哈希和新版本，不能静默覆盖原状态。		
强制分离	机器约束	科学意义
原始证据 / 派生记忆	<code>derived_context_is_evidence=false</code> ；原始字节保留、派生内容可重建	摘要可帮助检索，但不能替代文献、数据或运行记录
计划态 / 观测态	无兼容适配器时写入“未执行”；交付校验拒绝虚构结果图和数字	125 份计划不会被误报为 125 次实验
作者修订 / 独立评审	评审器不重写作者产物，另存 <code>recommendation</code> 与证据清单	避免同一模型链既当作者又替自己放行
已核验实例		
q001 独立评审 artifact 记录 18 个已验证文件及文件集合哈希；引用目录检查结果为 <code>verified_exact_union</code> （精确并集）。评审与阻断回执均作为新对象保存。		

6 临时智能体与可审计 Skills

6.1 按任务创建、按角色授权、完成后销毁




图 3: 临时智能体与 Skill 生命周期。上：最小权限任务执行；下：受控 Skill 进化设计。

Skill 类型	作用	审计字段
认知 Skill	收窄问题、设计反证、创新性三角审查、竞争解释	路由理由、来源、版本、内容哈希
方法 Skill	统计检验、数据处理、仿真/实验协议与终止条件	输入/输出 Schema、工具权限、证据绑定
治理 Skill	引用锁定、数值守卫、权限检查和交付验证	规则版本、拒绝原因、回执与上游哈希

运行证据	当前边界
q001 保存 3 份假设阶段和 1 份 post-pilot 临时交互记录；选定方法 manifest 记录 Skill 来源、内容哈希与路由结果。	受控进化已有开发/隐藏分区、影子评估和晋级代码契约；尚未发现完整真实晋级链，效果标记为【待补实验】。

固定上下文顺序：把“记得什么”变成可审计输入

角色政策	任务字节	允许 Skills	锁定文献	派生导航	已验证 pilot	输出 Schema
------	------	-----------	------	------	-----------	-----------

风险	代码控制	当前可验证对象
摘要污染事实	派生上下文显式标记为非证据；结论须回到原始文件	raw-memory envelope、派生记忆字段、证据绑定
Skill 越权取数	路由只装配容量内、角色允许的 Skill 与证据子集	路由理由、字符预算、Skill 内容哈希
任务后残留权限	完成或异常时生成 cleanup/emergency receipt	q001 交互产物；批量清理成功率【待补实验】

7 十二阶段科研闭环与状态机

7.1 科研状态机：只有证据满足条件，状态才能跃迁




图 4: 科研状态机。计划态不自动等于可执行态；科学评审和责任授权是独立跃迁条件。

q001 路径 真实运行	其余 124 题路径 计划态
问题接收 → 证据锁定 → 假设/计划 → 真实探索性 pilot → 指标验证 → 独立评审 → major_revision → 阻断 。没有创建正式交付报告。	完成问题编译与研究计划后保持 plan-only；由于没有兼容真实预实验适配器，不允许生成观测值或结果图。q050、q091、q119 属于该路径。

7.2 状态跃迁的最小判据

跃迁	必须满足
计划态 → 可执行态	数据授权、适配器、资源/安全审批、预注册指标和停止条件齐备
执行态 → 观测已验证	日志、参数、环境、原始数据、metrics 与 manifest 哈希一致
已评审 → 可交付	非阻断性科学建议 + 机器校验通过 + 责任主体明确授权

状态不变量：任何重试都不能绕过

不变量	系统要求
证据不降级	派生摘要、模型回忆和未验证文本不能替代锁定文献或原始文件
观测不伪造	计划态若无真实适配器与运行产物，只能保持 plan-only
失败不覆盖	重试创建新 checkpoint；旧 failure/review/block artifact 继续可见
授权不继承	新仪器、数据、资源和发布动作必须重新满足对应责任门禁

状态机的实际作用
它把“下一步该做什么”从自由对话判断改为显式条件判断：证据不足时收缩或阻断，证据充分时才允许进入执行、评审或交付。

7 十二阶段科研闭环与状态机（续）

7.3 十二阶段不可变 checkpoint




图 5: 十二阶段科研闭环。每一阶段均保存不可变 checkpoint；执行失败与评审阻断分别生成正式产物。

核心差异：过程即证据

传统生成链常把中间推理视为可丢弃缓存；AutoResearch 把阶段输入、输出、哈希、模型回执和失败原因共同作为审计对象。下游若要改变上游结论，只能创建新版本并保留差异。

反馈类型	例子	状态动作
机器可判定	Schema 缺字段、引用越界、数字无来源、manifest 漂移	立即拒绝；生成定位到字段/文件的回执
科学评审	零模型不足、方法引用不匹配、创新性检索不充分、外推过度	major/minor 分类；阻断或创建修订入口
人类责任	仪器、伦理、私有数据、云资源、公开发布	明确授权后才升级为可执行/可交付

当前闭环边界

q001 已验证“真实 pilot → 独立评审 → 阻断”；本次运行没有自动跨越阻断进入“修订 → 再执行 → 再评审”。因此文档只把评审问题写成下一轮任务候选，不声称已完成多轮自动自我改进。

checkpoint 与失败回执的最小字段

对象	必备字段	复核问题
阶段 checkpoint	stage、status、input/output hash、模型回执、时间戳	该阶段基于哪一版输入？是否被后续静默改写？
failure artifact	失败类型、错误信息、输入绑定、日志、最近可信状态	为什么失败？可以从哪里安全恢复？
review/block receipt	recommendation、问题分级、证据范围、是否创建交付	谁判定阻断？哪些证据进入了判断？

8 真实执行、数值守卫与三层门禁

8.1 从计划中的变量到可复核观测




图 6: 真实执行、数值/引用守卫与三层门禁。结构通过不代表科学通过，科学通过也不代表责任授权。

已发生: q001

真实计算产生原始 CSV、四类零模型 CSV、日志、参数、环境、metrics 与 manifest; 修订计划中的关键数字从验证文件绑定。独立评审为 major_revision, 随后生成阻断回执, delivery_report_created=false。

尚未量化

批量数字扰动检出率、引用越界率、数值守卫误报率、人类签署样本与三层门禁时延均为【待补实验】。存在代码控制点不等于已经获得统计性能结论。

8.2 三层门禁的职责边界

门禁	判断问题	典型输出	当前证据
机器	文件和字段是否完整、数字/引用是否可追溯?	pass / field-level reject / manifest mismatch	代码 + q001 运行
科学	方法、零模型、统计解释和创新性是否成立?	accept / minor / major / reject	q001 major revision
人类	是否授权真实仪器、伦理数据、资源与正式发布?	approve / hold / deny	流程接口; 签署样本待补

9 Science 125 问成果总览

9.1 规模化交付的真实状态，而非“125 次实验”



图 7: Science 125 问成果仪表盘。覆盖、交付格式和真实执行状态分开统计。

编号	领域问题	计划中的关键对照与判据	状态
q001	素数间隙序贯结构	五个固定区间; 四类零模型; $m = 5$ 并列感知排列熵	运行证据: 探索性 pilot
q050	Hubble 张力与 FLRW 破缺	时间延迟、BAO、SN Ia; $> 3\sigma$ 、 $\ln B > 5$ 、夹角 $< 30^\circ$	计划态; 未执行
q091	RQL 高频上限	1-60 GHz 扫频; 结参数扰动、磁通干预、BER/噪声带宽	计划态; 未执行
q119	工作记忆槽位可塑性	四周纵向、双任务/干扰; d 、 p 、 ΔBIC	计划态; 未执行

跨领域规模化任务编译

每题将开放问题压缩为可检查对象：Problem、Rationale、Technical Details、Datasets、Methods、Experiments、Results 与 References，并补充基线、指标、终止条件、资源和边界。125/125 的当前实测是**必备章节覆盖**；JSON Schema 级批量完整率仍为**【待补实验】**。

必须与成果包共同阅读的境界

“pilot 方案”表示可执行研究协议，不表示已产生观测。只有 q001 当前具有可核验的原始数据、零模型数据、日志、指标和 manifest。

每题交付对象的最小可执行语义

对象组	必备内容	允许的状态
科学目标	分析单位、主假设、竞争解释、最强反证	draft / evidence-locked
执行计划	数据源、变量、基线、方法、指标、终止条件、资源	plan-only / executable
观测与证据	原始文件、参数、环境、日志、metrics、manifest	absent / executed / verified
决策与交付	评审、版本差异、风险、授权与阻断原因	revise / blocked / deliverable

10 q001 真实 pilot: 可信闭环压力测试

10.1 从开放问题到“应当收缩结论”的真实反馈




图 8: q001 案例链路。系统保存弱化结论和负面评审，而非把探索性结果包装为突破。

零模型	零模型均值	观测 - 零模型	Holm p
局部分块置换	0.953933	−0.024580	0.020
全局置换	0.954408	−0.025055	0.020
残基路径条件置换	0.930507	−0.001153	0.020
wheel-210 约束	0.931604	−0.002251	0.020

独立评审：major revision

Major 1 方法引用与频率学派、并列感知实现不完全匹配。

Major 2 创新性三角检索与相邻工作比较不足。

Minor mod-30 / wheel-210 叙述不一致；小数精度需统一。

系统动作： **阻断**；未生成自动交付报告。

结果如何改变研究计划

观测均值为 0.929353。相对全局置换的差异在算术条件零模型下缩小约一个数量级，提示大部分表观结构可由已知模约束解释。剩余差异只构成扩大尺度和改进零模型的线索。

科学解释边界

五个区间是预先固定的计算 benchmark，不是从数轴总体随机抽取的样本；经验 p 与区间重采样范围仅描述本次计算。该 pilot 没有证明或否定任何素数猜想，也不构成正式数学证明。

可复核证据链

5 份原始区间 CSV + 5 份零模型 CSV + 环境/参数 + stdout/stderr + metrics + manifest + 源计划/代码快照；独立评审记录 18 个 verified files。完整路径与文件索引见附录。

下一轮候选任务与再进入条件

评审问题	下一轮任务候选	重新进入评审前的检查
方法引用不匹配	补入与实际频率学派、并列感知排列熵一致的方法来源	方法描述、代码实现与引用三者逐项对应
创新性证据不足	扩展相邻工作检索并给出实质差异，不只列题名	锁定目录更新；主张均有直接支持或收缩
模数叙述不一致	统一残基路径与 wheel-210 的实际实现及文字边界	参数、代码、图表和正文使用同一术语
数值精度漂移	从 metrics 重新绑定表格与正文，不手工改写	数字守卫和 manifest 复核通过

当前状态

以上为由评审问题导出的**候选修订任务**；本次运行在阻断态停止，尚未自动执行这些任务，也未完成再评审。

11 系统评估、消融与竞品对比

11.1 把“已有实测”与“计划评估”分开

指标/事实	当前结果	解释边界
计划与交付覆盖	125/125 计划；125 MD + 125 PDF	数量不代表实验执行
必备章节完整	125/125	是文档章节检查，不等于 JSON Schema 通过率
真实执行覆盖	q001: 1; 其余计划态: 124	当前不是 125 项实验
q001 证据文件	18 个 verified files	仅对本次独立评审范围
q001 引用集合	verified_exact_union	仅对该锁定目录与产物
科学门禁事件	1 次 major revision，自动交付被阻断	单样本事实，不外推“阻断率”

11.2 待补实验矩阵

实验组	目的 / 对照	自变量	指标 / 样本	回答的问题
Schema + manifest	验证对象与多格式一致；对照 = 无校验	校验器开/关、受控篡改	通过率、漂移检出；125 套	规模化输出是否真正遵守契约？
数字/引用对抗	检验守卫；对照 = 自由生成	错误类型/幅度、守卫开关	TPR/FPR、定位率；≥300 扰动	能否拒绝无来源数字与越界引用？
计划/观测隔离	防止未执行结果化；对照 = 无状态约束	契约/校验开关	混淆率；124 题 + 对抗提示	能否稳定保持 plan-only？
checkpoint 故障注入	验证恢复；对照 = 全流程重跑	12 个故障阶段、恢复策略	恢复率、重复量、一致性；每阶段 ≥5	长流程是否可从可信状态续跑？
反馈质量曲线	验证迭代增益；对照 = 单轮	0/1/2/3 轮、反馈来源	专家盲分、缺陷、工时；20 题	反馈何时提升、何时饱和？
模型/Skills 消融	分离系统贡献；对照 = 直接 Qwen	RAG、Agent、Skill、门禁组合	质量/溯源/成本；20–30 题	增益来自模型还是治理机制？
Skill 受控进化	验证影子晋级；对照 = 直接写回/不写回	隐藏评估、晋级策略	提升/回归/回滚；≥20 候选	能否学习而不污染安全与证据？
成本与人因	建立可落地预算；对照 = 直接 LLM/RAG	模型、上下文、并发	Token、费用、P50/P95、修改次数；≥30 题	质量约束下的实际代价是什么？

最小可执行消融设计

在 20 个跨学科问题上比较：A 直接 Qwen；B Qwen + 锁定检索；C B + 临时智能体/Skills；D 完整 AutoResearch（状态契约+守卫+门禁）。采用同一输入、预算与专家盲评量表，同时报告质量、证据错误、阻断表现、时间和成本。当前结果统一标记为【待补实验】。

评估纪律

本页没有用代码存在性代替效果数据，也没有生成虚假百分比、成本或质量提升。完整实验目的、对照、自变量、指标、样本和研究问题见配套 Markdown 审计稿。

赛前补证优先级

P0 | 125 题契约复核

全量 Schema + manifest；先回答“规模化是否真实合规”。

P0 | 数字/引用对抗

受控注入 ≥300 个扰动；报告 TPR、FPR 和定位率。

P1 | 故障恢复

12 阶段各 ≥5 次注入；报告恢复率与状态一致性。

P1 | 20 题消融

同输入、同预算、专家盲评；分离模型与治理贡献。

完成判据

只有在实验脚本、原始结果、统计汇总、失败样本与配置清单同时归档后，待补项才可从“实验设计”升级为“实测结论”。

11 系统评估、消融与竞品对比（续）

11.3 基于论文与官方仓库的克制对照

方案	公开材料明确的主要机制	与本方案相关的审计边界
普通大模型直接生成	基于输入上下文生成文本	不构成统一产品，证据状态、checkpoint 和科研门禁取决于具体实现
RAG 科研助手 [3]	检索器 + 生成器，将外部知识引入生成 [3]	原始 RAG 论文未定义计划/观测状态、数值守卫或科学责任门禁
通用多智能体（AutoGen）[4]	消息传递、事件驱动 Agent、人类与工具协作	官方框架面向通用编排；本文所列科研治理机制在公开材料中未明确为默认能力
AI Scientist[5]	在 ML 模板中完成想法、实验、论文写作与自动评审	官方仓库明确三类核心模板；本文的证据对象/数值守卫/三层门禁未在公开材料中明确说明
AI Scientist-v2[6]	移除人工代码模板，使用实验经理与渐进式 Agent 树搜索	论文报告端到端 ML 研究；本文治理维度若未披露，不推断为“没有”
AutoResearch	科研状态契约、临时 Agent/Skills、不可变闭环、守卫与门禁、125 问任务编译	q001 有运行证据；部分系统指标与 Skill 晋级仍待实验

比较结论

该表比较的是公开披露的系统重心与审计机制，不是同预算性能排行榜。没有共同任务实验时，不宣称 AutoResearch 全面优于既有系统；“公开材料中未明确说明”也不等于该系统绝对不具备相应能力。

12 工程实现、部署与复现

模型与工具接口

Qwen 为当前推理核心；兼容接口从配置读取端点、密钥和模型名。工具调用、领域适配器与模型层解耦。
状态：代码契约；跨供应商基准【待补实验】。

知识与版本底座

Obsidian 兼容 vault 保存文献、实验、问题、失败、Skill 与策略卡；原始证据与派生导航分层，Git 提供版本历史。
状态：代码契约 + 运行文件。

确定性交付

同一结构化计划渲染 Markdown、TeX、PDF 与 manifest；源哈希、证据绑定哈希和产物清单用于复核。
状态：运行证据 + 代码契约。

12.1 最小复现顺序



部署边界

默认沙箱；不在未授权情况下操作真实仪器、访问私有数据、租用云 GPU、提交论文或公开发布。凭据由环境注入，不写入运行目录、知识库和 Git 历史。

复现包的最小清单

复现层	必备对象	复核目标
环境	依赖锁、模型配置名、适配器版本、随机种子、硬件/系统快照	能否解释版本与环境差异
输入	题目快照、锁定文献目录、数据授权、Skill manifest、输入哈希	能否重建任务边界
执行	原始数据、参数、stdout/stderr、metrics、文件清单与 SHA-256	能否复算并发现篡改
决策	修订对象、独立评审、阻断/授权回执、parent hash 与版本差异	能否解释为何交付或停止

当前可复现样本

q001 已具备输入、运行、指标、manifest、独立评审和阻断回执；跨机器一键复现率与环境差异统计仍为【待补实验】。

13 安全边界、应用价值与下一阶段计划


13.1 安全不是附加声明，而是状态跃迁条件

最小权限 Agent 只读必要 Skill 与证据子集； 工具按白名单开放。	证据不可覆盖 原始字节、日志、失败和旧版本保留；摘要不得升级为证据。	危险动作审批 仪器、伦理数据、云资源和正式发布需要人类授权。
密钥隔离 模型凭据只从环境读取，不进入产物、vault 与仓库。	受控进化 候选 Skill 先影子评估；安全、审批与发布规则不可自改。	责任可追溯 自动评分只筛选；最终科学判断和高风险行为归责任主体。

13.2 应用价值

使用场景	可交付价值	不替代的责任
前沿问题预研	把宽问题快速编译为带证据、基线、指标、停止条件的方案集合	领域专家的科学判断与研究优先级
计算/仿真研究	连接适配器后形成原始产物—指标—评审的可复核链	模型有效性、资源授权与正式结论
实验协同与项目治理	保存进度、失败、版本差异和下一轮任务，减少信息断裂	伦理审批、仪器安全与发布责任

13.3 下一阶段路线图



结论

AutoResearch 已完成的不是“125 次自动科学发现”，而是 **125 个可继续推进的结构化研究任务**，以及一个能够暴露自身缺陷的 q001 真实闭环样本。其技术实质是让 Qwen 在证据对象、最小权限 Skills、不可变 checkpoint、数字/引用守卫和分层门禁中承担规模化认知劳动。q001 的 major revision 与交付阻断表明：系统的目标不是保证每次生成成功，而是保证科研状态不越过证据边界。

给评委的最终判断依据

若只看文字生成质量，本项目容易与 RAG 或多智能体系统混淆；若检查对象哈希、计划/观测分离、真实 pilot 文件、独立评审和阻断回执，可以看到其核心差异：**自动化必须经过可审计、可失败的科研门禁**。

阶段验收标准

阶段	进入下一阶段的必要证据	不满足时的动作
赛前补证完成	批量校验与对抗实验均有脚本、原始结果、统计摘要和 manifest	保留【待补实验】，不得把设计写成指标
反馈闭合完成	q001 修订依据、再运行文件、第二次独立评审和版本差异齐备	维持 blocked / revise，不创建正式交付
领域扩展完成	目标题获得数据/伦理/仪器授权并通过适配器验证与专家复核	维持 plan-only，优先输出待执行协议

长期边界

系统可以扩大科研认知劳动的吞吐量，但不能把自动化速度当作科学真值；安全策略、责任门禁、证据定义和发布规则始终保留人类监督与版本回滚。

附录：证据索引、复核路径与参考文献

A. 核心代码与机制映射

相对仓库路径	审计职责
src/autoresearch/competition/contest_direct_plan.py	科研计划与产物 Schema、输入/产物哈希 临时 Qwen Agent、角色/Skill/证据预算、清理回执 Skill 证据路由、来源、理由与内容哈希
src/autoresearch/competition/temporary_qwen_pool.py	
src/autoresearch/competition/contest_direct_skill_router.py	
src/autoresearch/competition/contest_direction_skill_evolution.py	开发/隐藏分区、影子评估、晋级与拒绝契约
src/autoresearch/knowledge/raw_memory.py	原始证据不可变信封与哈希验证 派生记忆非证据声明与可重建导航
src/autoresearch/competition/contest_direction_memory.py	
src/autoresearch/competition/contest_direction_research_loop_cli.py	十二阶段 checkpoint、阻断性评审状态
src/autoresearch/competition/contest_direct_plan_revision.py	pilot 占位绑定、已验证文件与数值守卫
src/autoresearch/competition/contest_reference_policy.py	锁定引用目录与未知引用 fail-closed
src/autoresearch/competition/science125_batch.py	125 题计划态批处理与“未执行”披露
src/autoresearch/competition/contest_direct_plan_render.py	Markdown/Tex/PDF/manifest 同源渲染与清单复核

B. 运行与成果路径

路径（本地审计环境）	内容
C:/Users/Z/Desktop/揭榜挂帅提交材料/delivery-125-plan	q001-q125: 125 份 Markdown + 125 份 PDF
E:/ai-researcher-loop/ai-researcher-loop-main/runs/contest-delivery/live-verify-q001-v2-20260816	
preexperiment/prime-gap-information-theory-v1	q001 完整运行、checkpoint、评审与阻断回执 5 份 raw CSV、5 份 null CSV、环境、参数、日志、metrics、manifest
independent-scientific-review/	
system-plan-scientific-review.json	18 个 verified files、引用精确并集、major revision
scientific-review-blocked-receipt.json	blocked_by_independent_scientific_review

C. q001 数值与样本边界

观测均值 0.929353；局部、全局、残基路径、wheel-210 四类零模型均值依次为 0.953933、0.954408、0.930507、0.931604；差值依次为 -0.024580、-0.025055、-0.001153、-0.002251。每类零模型 199 次重采样；五个固定 benchmark 区间的间隙数为 70,434、64,335、61,937、59,335、56,359。完整区间级统计以 metrics.json 为准。

参考文献

参考文献

[1] Kennedy, D.; Norman, C. What Don't We Know? *Science* 309, 75 (2005).

[2] Yang, A. et al. Qwen3 Technical Report. arXiv:2505.09388 (2025); official repository: <https://github.com/QwenLM/Qwen3>.

[3] Lewis, P. et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. *NeurIPS* 33 (2020), arXiv:2005.11401.

[4] Wu, Q. et al. AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversation. arXiv:2308.08155 (2023); official repository: <https://github.com/microsoft/autogen>.

[5] Lu, C. et al. The AI Scientist: Towards Fully Automated Open-Ended Scientific Discovery. arXiv:2408.06292 (2024); official repository: <https://github.com/SakanaAI/AI-Scientist>.

[6] Yamada, Y. et al. The AI Scientist-v2: Workshop-Level Automated Scientific Discovery via Agentic Tree Search. arXiv:2504.08066 (2025); official repository: <https://github.com/SakanaAI/AI-Scientist-v2>.

[7] Bandt, C.; Pompe, B. Permutation Entropy: A Natural Complexity Measure for Time Series. *Phys. Rev. Lett.* 88, 174102 (2002).

[8] Lemke Oliver, R. J.; Soundararajan, K. Unexpected Biases in the Distribution of Consecutive Primes. *PNAS* 113, E4446–E4454 (2016).

[9] W3C. PROV-O: The PROV Ontology. W3C Recommendation (2013), <https://www.w3.org/TR/prov-o/>.

材料真实性声明

本文依据榜单、源代码、运行 checkpoint、q001 真实 pilot 与 125 题既有交付包重构；未生成新的科学观测，未把计划态写成已执行结果，未删除负面评审，也未把 q001 表述为数学证明。外部系统比较仅使用论文、官方仓库或正式文档。